

Sistema para Identificação da Pinta Preta na Tangerina Ponkan, orientado por Visão Computacional

Arthur Parra, Danielli Reis, Guilherme Pereira,
Gustavo Kletelinger, Matheus Oliveira

Faculdade de Tecnologia do Estado de São Paulo

*arthur.silva56@aluno.cps.sp.gov.br, danieli.reis@aluno.cps.sp.gov.br,
guilherme.pereira26@aluno.cps.sp.gov.br, matheus.oliveira52@aluno.cps.sp.gov.br,
gustavo.kletelinger@aluno.cps.sp.gov.br*

Resumo

O projeto propõe o uso Visão Computacional para identificar precocemente a pinta preta dos citros na tangerina ponkan, analisando fotos capturadas por celular, classificando imagens e gerando relatórios e recomendações de manejo. Seu objetivo é otimizar medidas preventivas no campo, atender critérios de tempo de resposta e treinar uma IA com base de dados diversificada. Pazoti (2005) e Momeny et al. (2022) obtiveram altas taxas de acurácia na identificação do fungo usando redes neurais.

Palavras-chave: Pinta Preta dos Citros; Visão Computacional; Redes Neurais

1 Introdução

Os Objetivos de Desenvolvimento Sustentável (ODSs) foram adotados pela Organização das Nações Unidas [1] no ano de 2015, estabelecendo parâmetros para políticas nacionais sobre 17 temáticas que impactam o desenvolvimento humano em todos os países. Entre esses objetivos, o projeto de identificação da pinta preta (*Phyllosticta citricarpa*) por visão computacional relaciona-se profundamente com as ODSs 2, 9 e 12, que propõem medidas para garantir segurança alimentar com agricultura sustentável, fomento da inovação nos setores produtivos e eficiência no uso dos recursos naturais, respectivamente. Esses objetivos serão trabalhados com enfoque na tangerina ponkan (*Citrus reticulata*), uma cultura de destaque na região do Vale do Ribeira.

Sendo o Brasil o maior produtor mundial de laranja e suco de laranja (USDA, 2025) [2], torna-se evidente a importância nacional deste gênero conhecido como citros (*Citrus*), composto por espécies de laranja, limão, lima, tangerina/mexerica, pomelo/toranja e cidra. Dentre elas, a tangerina possui um grande valor socioeconômico no Vale do Ribeira e uma forte presença na agricultura familiar regional. Segundo o Departamento de Economia Rural (DERAL/SEAB) [3], a citricultura permanece a principal atividade de fruticultura paranaense, ocupando 6,9 mil hectares do estado no ano de 2024. Outro levantamento realizado pela Embrapa [4] no mesmo ano apontou que municípios do Vale do Ribeira aparecem entre os maiores produtores, como

Pariquera-Açu (SP) e Iguape (SP) com produção anual superior a 23 mil e 5,6 mil toneladas, respectivamente.

Nesse contexto, a conexão entre citricultura e agricultura familiar torna-se um pilar fundamental no desenvolvimento da região, considerando que "mais de 60% dos estabelecimentos agrícolas do Vale do Ribeira são compostos por pequenos agricultores familiares" (tradução nossa) (PAGASSINI et al., 2024) [5]. Para esse grupo social, a tangerina ponkan representa o atendimento de muitas necessidades, uma vez que se adaptou bem às condições edafoclimáticas locais. A drenagem do solo incentiva o crescimento de raízes profundas para melhor captação de água; enquanto o clima subtropical úmido, com alta umidade relativa do ar e temperaturas moderadas a altas, favorece a suculência e o tamanho dos frutos (BORGES et al., 2021) [6].

Essas características de agrado do consumidor definem a tangerina como um produto de comercialização principalmente *in-natura*, abastecendo não apenas o mercado externo, mas toda uma cadeia de pequenas propriedades que são afetadas diretamente pelos problemas da cultura. Por exemplo, a sazonalidade do mercado, em razão da safra concentrada entre os meses de abril e julho, pode afetar diretamente famílias que têm o cultivo de ponkan como fonte de renda principal. Outro fator decisivo é a produtividade, muitas vezes prejudicada por questões fitossanitárias, ou seja, pragas e doenças.

O cenário nacional de citros enfrenta grandes ameaças de agentes nocivos como insetos, bactérias e fungos. Uma das doenças mais importantes é a pinta preta ou mancha preta dos citros, a qual, segundo Silva Junior (2016, p. 14) [7], foi relatada em 1980 no estado do Rio de Janeiro e encontra-se praticamente em todas as regiões citrícolas do país. Trata-se de uma doença fúngica causada pelas variações de reprodução sexuada *Phyllostictina citricarpa* e assexuada *Guignardia citricarpa*, caracterizada pela queda prematura dos frutos, cujas cascas são acometidas por lesões que também desqualificam significativamente o produto para comercialização. Ademais, lesões de pinta preta são dotadas de certa variabilidade e podem se assemelhar a danos mecânicos ou insetos, confundindo o produtor. Os principais sintomas são manchas dura, sardenta, virulenta, rendilhada, trincada e a falsa melanose, com manifestação favorecida pela exposição ao sol em altas temperaturas. Portanto, "o manejo da doença em pomares para o mercado interno deve ser muito rigoroso e eficiente" (SILVA JUNIOR et al., 2016) [7].

Para o enfrentamento de desafios fitossanitários como esse, o conceito de agricultura de precisão (AP) tem se destacado como uma abordagem inteligente da prática agrícola. Segundo Molin, Amaral e Colaço (2015) [8], a AP esteve fortemente vinculada ao georreferenciamento no seu início, e mais recentemente pode ser entendida como a aplicação da tecnologia da informação (TI) em campo. Sua finalidade de reduzir custos e aumentar produtividade baseia-se na compreensão de que as propriedades agrícolas não são uniformes espacialmente ou ao longo do tempo, o que exige o desenvolvimento de estratégias para gerenciar a heterogeneidade das lavouras e seus respectivos problemas.

Nesse retrato, a visão computacional (VC) "pode ser empregada na detecção de doenças e pragas, na estimação de safra e na avaliação não invasiva de atributos como qualidade, aparência e volume, além de ser componente essencial em sistemas robóticos agrícolas" (SANTOS et al., 2020) [9]. O mesmo estudo aborda a classificação de padrões associados a objetos de interesse e sintomas de doenças e pragas como problemas perceptuais abordados pela visão computacional, geralmente capturados em imagens por câmeras acopladas em tratores, robôs e drones. Cita também os problemas geométricos, advindos da perda de informações de profundidade em imagens bidimensionais e que podem ser recuperadas por algoritmos de visão computacional que interpretem múltiplas imagens de uma mesma cena.

2 Objetivo

Desenvolver um sistema capaz de identificar sintomas da pinta preta na tangerina ponkan, capturados em foto via câmera de telefone celular, utilizando métodos de Inteligência Artificial

e Visão Computacional de modo a otimizar as medidas preventivas em campo.

Em paralelo, o projeto possui objetivos secundários que complementam sua finalidade principal:

- Emitir recomendações de manejo personalizadas para o produtor, baseadas em dados climáticos;
- Gerar mapa dos pontos de infecção e áreas de risco para o pomar, baseado em geolocalização;
- Utilizar conjuntos de dados organizados e diversificados com sintomas da pinta preta para treinamento e teste de algoritmo de aprendizado de máquina.

3 Estado da Arte

A detecção automatizada de doenças na agricultura tornou-se essencial para reduzir perdas produtivas e substituir a subjetividade da inspeção visual humana. Para atender a essa demanda, a literatura recente abandonou o processamento manual de imagens em favor das redes neurais convolucionais. Esse avanço reflete a necessidade atual do setor: criar sistemas de visão computacional rápidos, capazes de operar sob as interferências de um ambiente real de plantação e acessíveis diretamente por smartphones.

As abordagens iniciais para o diagnóstico de doenças apoiaram-se em Redes Neurais Artificiais (RNAs) clássicas e extração manual de características. Um exemplo desse cenário é o trabalho de Ribeiro, Castro Jorge e Paiva (2012) [10], cujo objetivo foi diferenciar o greening de outras doenças foliares e deficiências nutricionais em citros, uma vez que a identificação visual é falha e a técnica molecular PCR (Reação em Cadeia da Polimerase) é cara e demorada. Foram usadas amostras de 60 folhas de citros com sintomas de greening, clorose variegada dos citros, rubelose e deficiências de magnésio, manganês e zinco, cujas imagens foram digitalizadas em scanner fotográfico.

O pré-processamento baseou-se na segmentação das cores verdes, amarelas e marrons das manchas do greening por meio de uma RNA treinada com 46 imagens, enquanto as restantes foram utilizadas para validação. Todo o treinamento foi feito com pixels rotulados, processados por três camadas escondidas e convertidos em máscaras binárias que definiam as manchas. Em seguida, foram extraídos descritores de forma por meio de cálculos matemáticos aplicados às máscaras binárias, gerando atributos armazenados em vetores e posteriormente organizados em quadrantes que mediam a assimetria das manchas. A classificação das doenças também utilizou RNA e construiu escalas de severidade dos sintomas em diagramas.

O estudo destaca desafios como a alta similaridade entre sintomas, a amostra reduzida de 60 folhas e o uso isolado da cor amarela, que não foi suficiente para discriminar o greening. Ainda assim, a segmentação por cor utilizando RNA obteve 96,04% de precisão. Entretanto, na classificação geral considerando todas as doenças, os resultados variaram entre 43% e 63%. Concluiu-se que a RNA foi viável para auxiliar na diferenciação do greening e pode complementar a inspeção visual no campo, porém é necessário combinar a classificação de cores com descritores de forma para elevar a acurácia (Ribeiro; Castro Jorge; Paiva, 2012) [10].

Superando as limitações da extração manual das RNAs clássicas, Marques, Pontelli e Paiva (2022) [11] propuseram a identificação do greening em plantações de citros por meio de Redes Neurais Convolucionais Profundas (CNNs). A metodologia baseou-se na técnica de aprendizado por transferência utilizando a arquitetura InceptionV3, implementada em linguagem Python com as bibliotecas Keras, Tensorflow, Numpy e Sklearn. As imagens foram capturadas por câmeras digitais e divididas em dois conjuntos estratégicos: folhas com fundo homogêneo e folhas com fundo real. O principal desafio de estudo foi garantir que a rede extraísse características consis-

tentes lidando com ruídos visuais típicos de ambientes abertos, como solo, galhos e variações de iluminação.

Para aumentar a variabilidade e quantidade de dados, aplicou-se a técnica de data augmentation, submetendo as imagens a transformações de translação, rotação, zoom e variação de brilho. O treinamento comparou duas abordagens: treinar apenas as camadas finais ou ajustar todos os pesos neurais da rede. Os resultados demonstram que o treinamento de todas as camadas foi substancialmente superior, atingindo 99,33% de acurácia nas imagens de estúdio. No teste de maior exigência, com fundo real de campo, o modelo sustentou uma precisão de 95,99%. Concluiu-se que o uso de CNNs e câmeras digitais é capaz de superar as taxas de erro da inspeção visual, identificando plantas doentes diretamente no ambiente de plantação.

Um estudo mais recente e próximo dos objetivos deste projeto foi desenvolvido por Momeny et al. (2022) [12], que aprofundaram o uso de redes neurais convolucionais (CNNs) aliadas a uma estratégia denominada *learning-to-augment*, responsável por criar dados artificiais para treinamento do modelo na detecção da pinta preta (*black spot*) em laranjas. O conjunto de dados utilizado totalizou 1.896 imagens de laranjas divididas em classes de frutos verdes, meia-maturação, maduros e com pinta preta, todas capturadas com um smartphone Samsung SM-J500H com câmera de 4128×2322 pixels.

Também foi utilizada uma versão do MATLAB como software de processamento, e diferentes modelos de *deep learning* foram avaliados, como MobileNetV2, GoogleNet e DenseNet201. Os resultados demonstraram melhor desempenho do modelo ResNet50, que alcançou acurácia total de 99,5%, com 100% de sensibilidade e especificidade, ou seja, sem deixar de identificar frutos doentes nem confundir frutos saudáveis (Momeny et al., 2022) [12].

Enquanto o trabalho inicial de Ribeiro, Castro Jorge e Paiva (2012) [10] evidencia o esgotamento dos métodos matemáticos manuais de processamento de cor em imagens de scanner, Marques, Pontelli e Paiva (2022) [11] provam a viabilidade das CNNs para contornar ruídos visuais em ambientes reais de plantação usando câmeras comuns. Já Momeny et al. (2022) [12] demonstraram que um sistema rápido e de baixo custo, utilizando câmeras de smartphones, pode ser aplicado à detecção da pinta preta. Além disso, o estudo obteve êxito no uso da técnica *learning-to-augment* em comparação com métodos tradicionais de aumento de amostras, como rotação e *flip*. Considerando que as CNNs são tipos específicos de RNAs especializadas em dados com estrutura espacial, como imagens, áudios e vídeos, esse estudo oferece direcionamentos importantes para o desenvolvimento da rede neural deste projeto.

4 Metodologia

Esta pesquisa caracteriza-se como um estudo de natureza aplicada com abordagem experimental, voltada ao desenvolvimento de um sistema multiplataforma de pré-diagnóstico fitossanitário para a identificação precoce da Pinta Preta (*Phyllosticta citricarpa*) na cultura da tangerina Ponkan, visando a otimização de medidas preventivas no Vale do Ribeira.

O sistema será estruturado em uma arquitetura de microsserviços. A orquestração da Interface de Programação de Aplicações (API) será realizada em Node.js, enquanto o processamento de Inteligência Artificial (IA) utilizará a linguagem Python. A persistência dos dados ocorrerá em banco de dados MySQL via Object-Relational Mapping (ORM) Sequelize, com o suporte do Redis e da biblioteca BullMQ para o gerenciamento de filas assíncronas.

A comunicação entre os módulos ocorrerá via API com estilo arquitetural Representational State Transfer (REST). Para garantir a responsividade da interface (React Native e Next.js), o processamento de imagens será delegado a workers assíncronos. O pipeline de tratamento utilizará a biblioteca Sharp para redimensionamento (224×224 px), filtragem de ruído, ajustes de contraste, conversão para padrão sRGB e extração de buffer binário.

A inferência será realizada por uma Rede Neural Convolucional (CNN) de duas fases: o algoritmo YOLO detectará as lesões e a rede EfficientNet as classificará, adotando um limiar

de confiança de 80%. O sistema operará através dos módulos de Diagnóstico, Contexto, Recomendação (baseado em protocolos da Embrapa e Fundecitrus) e Diagramação, utilizando a estratégia de "deleção lógica" para assegurar a rastreabilidade dos registros.

O fluxo da arquitetura (Figura 1) iniciar-se-á com o upload das imagens pelo cliente (Etapa A), que serão salvas pela API e registradas como "Pendente" (Etapa B). O job será enviado à fila assíncrona (Etapa C), onde o worker acionará o tratamento via Sharp (Etapa D).

A imagem tratada será submetida ao modelo de IA (Etapa E) para inferência. Caso o diagnóstico seja positivo (Etapa F), o sistema aplicará as regras de negócio da Embrapa para gerar um Plano de Ação (Etapa G) e persistirá o resultado no MySQL (Etapa H).

Ao finalizar, o sistema atualizará o status da análise para "Concluída" (Etapa I), disparando a notificação de resultado para a interface do usuário (Etapa J). Se o diagnóstico for negativo, o sistema desativará a análise, mantendo o banco de dados otimizado.

Este ciclo assíncrono garantirá a escalabilidade do sistema. Para validar a arquitetura, serão realizados testes em ambiente controlado, simulando acessos sob variadas condições de luz e ruído, visando aferir a robustez do pipeline e a precisão da classificação final da IA.




Figura 1: A figura ilustra o comportamento do sistema durante o fluxo de processamento de imagens.

Referências

- [1] Nações Unidas. (2025) Objetivos de desenvolvimento sustentável (ods). [Online]. Available: <https://brasil.un.org/pt-br/sdgs>
- [2] USDA. (2025) Citrus: circular técnica para citros. [Online]. Available: <https://apps.fas.usda.gov/psdonline/circulars/citrus.pdf>
- [3] Departamento de Economia Rural (DERAL), “Boletim semanal deral nº 14/2024,” Secretaria da Agricultura e do Abastecimento do Paraná (SEAB), Curitiba, Tech. Rep., 2024. [Online]. Available: https://www.agricultura.pr.gov.br/sites/default/arquivos_restritos/files/documento/2024-04/boletim_semanal_14_deral_04_abr_24.pdf
- [4] Empresa Brasileira de Pesquisa Agropecuária (EMBRAPA), “Produção brasileira de tangerina por município,” EMBRAPA Mandioca e Fruticultura, Cruz das Almas, Tech. Rep., 2024. [Online]. Available: https://www.cnpmf.embrapa.br/Base_de_Dados/index_pdf/dados/brasil/tangerina/b32_tangerina.pdf
- [5] J. A. V. Pagassini, L. C. F. d. Almeida, and M. C. d. G. Gasparoto, “Perception and adoption of integrated plant disease management by family farmers in ribeira valley (são paulo state, brazil),” *Revista Caderno Pedagógico*, vol. 21, no. 3, pp. 1–22, 2024.

- [6] A. L. Borges, E. A. Girardi, and L. d. S. Souza, “Recomendação de calagem e adubação,” in *Calagem e adubação para os citros (laranjeiras, limeiras-ácidas e tangerineiras)*. EMBRAPA, 2020. [Online]. Available: <https://www.infoteca.cnptia.embrapa.br/infoteca/bitstream/doc/1134672/1/cap9-livro-RecomendacaoCalagemAdubacao-AnaLuciaBorges-AINFO-1.pdf>
- [7] G. J. Silva-Junior, E. Feichtenberger, M. B. Spósito, L. Amorim, R. B. Bassanezi, and A. d. Goes, *Pinta preta dos citros: a doença e seu manejo*, 1st ed. Araraquara: Fundecitrus, 2016. [Online]. Available: <https://www.fundecitrus.com.br/wp-content/uploads/2025/07/Livro-Pinta-Preta.pdf>
- [8] J. P. Molin, L. R. d. Amaral, and A. Colaço, *Agricultura de Precisão*. Oficina de Textos, 2015. [Online]. Available: <https://play.google.com/store/books/details?id=MX7jCgAAQBAJ>
- [9] T. T. Santos, J. G. A. Barbedo, S. Ternes, J. Camargo Neto, L. V. Koenigkan, and K. X. S. d. Souza, “Visão computacional aplicada na agricultura,” in *Agricultura Digital: Pesquisa, Desenvolvimento e Inovação nas Cadeias Produtivas*, S. M. Fonseca, S. Massruhá, and outros, Eds. Brasília, DF: Embrapa, 2020, pp. 146–164, capítulo 6. [Online]. Available: <https://www.alice.cnptia.embrapa.br/alice/bitstream/doc/1126261/1/LV-Agricultura-digital-2020-cap6.pdf>
- [10] P. P. E. Ribeiro, L. A. Castro Jorge, and M. S. V. Paiva, “Diferenciação do greening de outras doenças foliares em citros utilizando técnicas de processamento de imagens,” 2012. [Online]. Available: <https://swfrec.ifas.ufl.edu/hlb/database/pdf/00002955.pdf>
- [11] M. N. Marques, C. O. Pontelli, and E. C. de Paiva, “Identificação de huanglongbing (hlb) em plantações de citros utilizando redes convolucionais profundas,” *Congresso Brasileiro de Automática (CBA)*, 2022. [Online]. Available: https://sba.org.br/open_journal_systems/index.php/cba/article/view/3507/3036
- [12] M. Momeny *et al.*, “Detection of citrus black spot disease and ripeness level in orange fruit using learning-to-augment incorporated deep networks,” *Ecological Informatics*, vol. 71, p. 101829, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S1574954122002795>